

Tecnicatura Superior Ciencia de Datos e Inteligencia Artificial

COBERTURAMED - DETECCIÓN AUTOMÁTICA DE CAMPOS EN TICKETS HOSPITALARIOS

Proyecto ABP

Materia: Procesamiento de Imágenes

Integrantes:

- Emilce Robles
- Marini Ian

Docente:

- Carlos Charletti

1. NOMBRE DEL PROYECTO: CoberturaMed: sistema de detección automática de campos en tickets hospitalarios mediante procesamiento de imágenes y YOLOv8.

2. TIPO DE PROYECTO: Proyecto tecnológico de investigación aplicada.

3. ESPACIO CURRICULAR O ESPACIOS PARTICIPANTES EN EL MÓDULO:

Procesamiento de Imágenes.

4. EJES TEMÁTICOS:

En instituciones de salud, clínicas y hospitales se generan diariamente tickets y comprobantes que contienen información relevante para la gestión administrativa. Estos documentos pueden incluir datos de paciente, factura, autorización, códigos, cantidades, copagos, cuotas moderadoras, totales, ingresos y valores unitarios.

La carga manual de esta información demanda tiempo, genera tareas repetitivas y puede provocar errores de transcripción. Por este motivo, resulta relevante explorar soluciones que permitan detectar automáticamente las regiones de interés dentro de los documentos, como etapa previa a una posible extracción textual mediante OCR.

El problema principal consiste en localizar visualmente los campos relevantes dentro del ticket. No se busca clasificar la imagen completa, sino detectar múltiples objetos o regiones administrativas dentro de una misma imagen.

- Procesamiento digital de imágenes: escala de grises, suavizado, binarización y detección de bordes.
- Visión por computadora aplicada a documentos administrativos hospitalarios.
- Detección de objetos mediante bounding boxes.
- Aprendizaje profundo aplicado a imágenes documentales.
- Modelo YOLOv8 para detección automática de campos.
- Análisis exploratorio de datasets visuales.
- Evaluación de modelos mediante Precision, Recall, mAP50 y mAP50-95.
- Interpretación de resultados, limitaciones y mejoras futuras.

5. PROBLEMÁTICAS:

El procesamiento administrativo de tickets hospitalarios presenta desafíos asociados a la lectura, carga y validación de información documental. En un flujo manual, cada ticket debe ser revisado por una persona para ubicar campos relevantes y registrar los datos en un sistema.

Esta dinámica puede generar demoras, errores humanos y dependencia de tareas repetitivas. Además, la variabilidad visual de los documentos, la presencia de texto pequeño y la cercanía entre campos pueden dificultar la automatización directa.

CoberturaMed aborda esta problemática mediante un modelo de detección de objetos capaz de localizar automáticamente los campos administrativos dentro del ticket, generando una base técnica para futuras etapas de lectura OCR y validación automática.

6. FUNDAMENTACIÓN:

La automatización del procesamiento documental es una aplicación concreta de la visión por computadora. En el contexto de salud, puede contribuir a reducir carga operativa, mejorar la trazabilidad documental y disminuir errores asociados a la carga manual.

Desde el punto de vista técnico, el proyecto integra dos enfoques complementarios. Primero, utiliza técnicas clásicas de procesamiento de imágenes para comprender la estructura visual del documento. Luego, implementa aprendizaje profundo mediante YOLOv8 para resolver la detección localizada de campos.

Esta combinación permite demostrar comprensión de los fundamentos de la materia y, al mismo tiempo, construir un prototipo aplicable a un escenario documental real.

VISIÓN DEL PROYECTO:

Desarrollar una solución basada en inteligencia artificial capaz de identificar automáticamente campos de interés dentro de tickets hospitalarios, contribuyendo a la transformación digital de procesos administrativos vinculados al ámbito sanitario.

DISEÑO DE LOS OBJETIVOS

Objetivo general: Diseñar e implementar un sistema basado en visión por computadora capaz de detectar automáticamente campos relevantes en tickets hospitalarios mediante técnicas de procesamiento de imágenes y aprendizaje profundo.

Objetivos específicos:

- Analizar y preparar un conjunto de imágenes de tickets hospitalarios para su utilización en tareas de detección de objetos.
- Aplicar técnicas de procesamiento de imágenes para comprender las características visuales presentes en el dataset.
- Entrenar un modelo de detección de objetos utilizando YOLOv8 para identificar campos específicos dentro de los tickets.
- Evaluar el desempeño del modelo mediante métricas de precisión y análisis visual de resultados.
- Proponer posibles aplicaciones futuras orientadas a la automatización documental en instituciones de salud.

Metas: Las metas cuantifican los objetivos en términos de tiempo, calidad y producto esperado.

Meta	Indicador de cumplimiento	Resultado esperado
M1	Dataset cargado, validado y explorado.	Contar con train, valid y test analizados mediante tablas, gráficos y conclusiones.
M2	Aplicación de técnicas de procesamiento de imágenes.	Generar evidencias de escala de grises, Gaussian Blur, binarización y Canny.
M3	Dataset convertido a formato YOLO.	Generar estructura images/labels y archivo data.yaml con 10 clases.
M4	Modelo YOLOv8 entrenado.	Obtener archivo best.pt y resultados de entrenamiento.
M5	Modelo evaluado.	Registrar Precision, Recall, mAP50 y mAP50-95 sobre test.

7. SELECCIÓN DE ACCIONES

OBJETIVO ESPECÍFICO	ACCIONES
Analizar y preparar un conjunto de imágenes de tickets hospitalarios para su utilización en tareas de detección de objetos.	Revisar estructura train/valid/test; cargar archivos _annotations.csv; validar nombres de clases; verificar bounding boxes; analizar distribución de imágenes y anotaciones.
Aplicar técnicas de procesamiento de imágenes para comprender las características visuales presentes en el dataset.	Seleccionar imágenes de muestra; convertir a escala de grises; aplicar Gaussian Blur; aplicar binarización; ejecutar Canny Edge Detection; guardar evidencias visuales.
Entrenar un modelo de detección de objetos utilizando YOLOv8 para identificar campos específicos dentro de los tickets.	Convertir anotaciones RetinaNet a formato YOLO; generar data.yaml; configurar modelo YOLOv8n; entrenar con parámetros definidos; guardar el mejor modelo best.pt.
Evaluar el desempeño del modelo mediante métricas de precisión y análisis visual de resultados.	Evaluar sobre test; registrar Precision, Recall, mAP50 y mAP50-95; generar predicciones limpias; comparar anotación real contra predicción del modelo.
Proponer posibles aplicaciones futuras orientadas a la automatización documental en instituciones de salud.	Identificar limitaciones; proponer integración con OCR; plantear mejoras con más datos; sugerir validación automática e integración con sistemas administrativos.

8. CRONOGRAMA:

Se propone un presupuesto de tiempo estimativo organizado en cuatro semanas de trabajo.

Actividad / objetivo	Semana 1	Semana 2	Semana 3	Semana 4
Objetivo 1: análisis y preparación del dataset	Revisión de estructura y carga de anotaciones	EDA y validaciones		
Objetivo 2: procesamiento de imágenes		Escala de grises, binarización, Gaussian Blur y Canny		

Objetivo 3: entrenamiento YOLOv8		Conversión a YOLO	Entrenamiento del modelo	
Objetivo 4: evaluación de resultados			Métricas y predicciones	Comparación visual y análisis
Objetivo 5: documentación y mejoras futuras				Informe ABP, limitaciones, mejoras y preparación de defensa

9. METODOLOGÍA DE DESARROLLO

El proyecto se organiza con una lógica de trabajo inspirada en CRISP-DM y adaptada a un problema de procesamiento de imágenes. El flujo incluye comprensión del problema, comprensión de los datos visuales, preparación del dataset, modelado, evaluación y comunicación del producto final.

Fase	Aplicación en CoberturaMed
Comprensión del problema	Identificación de la necesidad de detectar campos administrativos en tickets hospitalarios.
Comprensión de los datos	Análisis de imágenes, anotaciones, clases, particiones, resoluciones, bounding boxes y distribución espacial.
Preparación de los datos	Validación de anotaciones, conversión a YOLO, creación de data.yaml y control de labels.
Modelado	Entrenamiento de YOLOv8n para detección de objetos.
Evaluación	Medición de Precision, Recall, mAP50 y mAP50-95; análisis de predicciones.
Comunicación	Notebook, documentación técnica, figuras, conclusiones, limitaciones y mejoras futuras.

10. COMPRENSIÓN DE LOS DATOS

El dataset se compone de imágenes de tickets hospitalarios organizadas en tres particiones: train, valid y test. Cada imagen cuenta con anotaciones que indican la ubicación de campos administrativos mediante coordenadas de bounding boxes.

Partición	Imágenes	Anotaciones	% imágenes	% anotaciones	Anotaciones por imagen
train	113	1.140	70,19 %	69,68 %	10,09
valid	32	325	19,88 %	19,87 %	10,16
test	16	171	9,94 %	10,45 %	10,69
Total	161	1.636	100 %	100 %	10,16




Figura 1. Distribución de imágenes por partición.

La mayor cantidad de imágenes se concentra en la partición de entrenamiento, lo cual es adecuado para un modelo supervisado. Las particiones de validación y prueba quedan reservadas para monitorear el rendimiento y evaluar la capacidad de generalización.




Figura 2. Promedio de anotaciones por imagen según partición.

Los promedios de anotaciones por imagen son similares entre train, valid y test. Esto indica que las particiones presentan una complejidad documental comparable.

11. ANÁLISIS EXPLORATORIO DE DATOS (EDA)

Distribución general de clases

El dataset contiene diez clases de campos administrativos: autorizacion, cantidad, codigo, copago, cuota_moderadora, factura, ingreso, paciente, total y valor_unitario. La distribución general se mantiene relativamente equilibrada.

Clase	Cantidad	Porcentaje
valor_unitario	173	10,57 %

cantidad	173	10,57 %
codigo	171	10,45 %
total	160	9,78 %
factura	160	9,78 %
cuota_moderadora	160	9,78 %
paciente	160	9,78 %
copago	160	9,78 %
autorizacion	160	9,78 %
ingreso	159	9,72 %




Figura 3. Distribución general de anotaciones por clase.

La diferencia entre la clase con menor cantidad de anotaciones y la clase con mayor cantidad es baja. Esto reduce el riesgo de que el modelo aprenda de forma sesgada hacia una única clase dominante.

Distribución de clases por partición

Además del balance global, es necesario verificar que cada clase esté representada en train, valid y test. Esto permite que el modelo aprenda cada clase, ajuste su desempeño y sea evaluado correctamente.




Figura 4. Distribución porcentual de clases por partición.

Cantidad de anotaciones por clase y partición

Clase	train	valid	test
autorizacion	112	32	16
cantidad	119	34	20
codigo	118	34	19
copago	112	32	16
cuota_moderadora	112	32	16
factura	112	32	16
ingreso	112	31	16
paciente	112	32	16
total	112	32	16
valor_unitario	119	34	20
	Partición		

Figura 5. Matriz de cantidad de anotaciones por clase y partición.

Cantidad de anotaciones por imagen

El análisis de anotaciones por imagen permite revisar si cada ticket contiene una cantidad estable de campos administrativos. En CoberturaMed, la mayoría de las imágenes contiene 10 anotaciones.

Cantidad de anotaciones	Cantidad de imágenes	Porcentaje
9	3	1,88 %
10	148	92,50 %
13	5	3,12 %
16	4	2,50 %




Figura 6. Distribución de anotaciones por imagen.

Tamaño relativo de bounding boxes

El tamaño relativo de los bounding boxes permite evaluar qué proporción de la imagen ocupa cada campo. Esta información es relevante porque los campos más pequeños suelen ser más difíciles de detectar.




Figura 7. Tamaño medio relativo de los campos anotados.




Figura 8. Variabilidad del tamaño relativo de los campos anotados.

El campo cantidad presenta el menor tamaño relativo promedio, mientras que campos como paciente, factura y total ocupan regiones más visibles. Esta diferencia ayuda a interpretar por qué algunos campos pueden requerir mayor precisión visual durante el entrenamiento.

Análisis espacial de anotaciones

El mapa espacial permite observar dónde suelen ubicarse los campos dentro del ticket. En documentos administrativos, la ubicación de los campos suele seguir una estructura relativamente estable.




Figura 9. Mapa espacial de ubicación de campos anotados.

Las anotaciones muestran agrupamientos por zonas, lo cual indica que el dataset posee patrones espaciales que el modelo puede aprender. Esto refuerza la elección de un modelo de detección de objetos.

Conclusiones del EDA

El análisis exploratorio muestra que el dataset es apto para entrenar un modelo de detección de objetos con YOLOv8. Las clases presentan una distribución equilibrada, las particiones mantienen presencia de los campos principales y las imágenes poseen una estructura documental consistente.

12. PREPARACIÓN DE LOS DATOS

El dataset original utiliza anotaciones en formato RetinaNet o equivalente. Para entrenar YOLOv8 fue necesario convertir las coordenadas de las cajas al formato YOLO, donde cada anotación se expresa mediante clase, centro x, centro y, ancho y alto, normalizados entre 0 y 1.

Elemento	Resultado
Formato inicial	Anotaciones tipo RetinaNet / CSV con xmin, ymin, xmax, ymax y class.
Formato final	YOLO: class_id, x_center, y_center, width, height normalizados.
Archivo de configuración	data.yaml con path, train, val, test, nc=10 y lista de clases.
Validación final	Cada imagen de train, valid y test cuenta con su archivo .txt correspondiente.

Partición	Imágenes YOLO	Labels YOLO	Coinciden
train	113	113	True
valid	32	32	True
test	16	16	True

La validación de archivos YOLO confirma que la estructura generada es consistente y se encuentra lista para el entrenamiento del modelo.

13. TÉCNICAS DE PROCESAMIENTO DE IMÁGENES APLICADAS

Antes del entrenamiento se aplicaron técnicas clásicas de procesamiento digital de imágenes para comprender la estructura visual de los tickets hospitalarios. Estas técnicas no reemplazan a YOLOv8, sino que permiten observar contraste, bordes, zonas de texto, ruido visual y separaciones internas del documento.

- Conversión a escala de grises: simplifica la imagen y permite analizar la intensidad de los píxeles.
- Gaussian Blur: suaviza la imagen y reduce ruido o pequeñas variaciones visuales.
- Binarización: separa zonas claras y oscuras para resaltar texto y líneas.
- Canny Edge Detection: identifica contornos y cambios fuertes de intensidad dentro del ticket.



Figura 10. Ejemplo de técnicas de procesamiento aplicadas a un ticket.

Estas evidencias demuestran que los tickets poseen estructura visual analizable: zonas de texto, bordes, contraste y patrones documentales. Esto justifica el uso de técnicas de visión por computadora y aprendizaje profundo.

14. MODELADO CON YOLOv8

Selección y justificación del modelo

Para resolver el problema se seleccionó YOLOv8, un modelo de detección de objetos capaz de identificar múltiples regiones dentro de una misma imagen. Esta elección es adecuada porque CoberturaMed no requiere clasificar el ticket completo, sino localizar varios campos administrativos.

Criterio	Justificación
Tipo de problema	Detección de múltiples campos dentro de una misma imagen.
Salida requerida	Clase del campo y ubicación mediante bounding box.
Estructura del documento	Los tickets presentan regiones administrativas repetidas y localizables.
Tamaño del dataset	YOLOv8n permite trabajar con una versión liviana y adecuada para prototipo académico.
Evaluación	Permite obtener métricas específicas de detección: Precision, Recall, mAP50 y mAP50-95.

Configuración del entrenamiento

Parámetro	Valor utilizado	Justificación
Modelo base	yolov8n.pt	Versión liviana, adecuada para un prototipo y entrenamiento en CPU.
Épocas	25	Cantidad suficiente para observar aprendizaje sin extender excesivamente el entrenamiento.
Tamaño de imagen	960	Mantiene detalle visual de campos pequeños dentro del ticket.
Batch size	2	Configuración compatible con recursos disponibles en CPU.
Confianza	0,25	Umbral utilizado para visualizar predicciones iniciales.
Dispositivo	CPU	Entrenamiento ejecutado en equipo local sin GPU dedicada.

Curvas de entrenamiento

Durante el entrenamiento se registraron pérdidas de caja, clasificación y distribución focal, tanto en entrenamiento como en validación. Las curvas muestran una disminución progresiva de los errores, lo cual indica que el modelo fue aprendiendo patrones relevantes del dataset.




Figura 11. Curvas principales de entrenamiento y validación de YOLOv8.

La disminución progresiva de las pérdidas indica que el modelo fue ajustando sus predicciones durante las 25 épocas de entrenamiento. Las curvas de validación también muestran una tendencia descendente, lo que sugiere aprendizaje útil sobre imágenes no utilizadas directamente para ajustar los pesos.

EVALUACIÓN DEL MODELO

El modelo se evaluó sobre el conjunto de prueba, compuesto por 16 imágenes y 171 instancias anotadas. Las métricas utilizadas permiten analizar tanto la capacidad de detección como la precisión en la localización de los campos.

Métrica	Valor	Porcentaje	Interpretación
Precision	0,9585	95,85 %	De todas las detecciones realizadas, proporción que fue correcta.
Recall	0,9339	93,39 %	De todos los objetos reales, proporción que logró detectar el modelo.
mAP50	0,9685	96,85 %	Precisión media con umbral IoU de 0,50.
mAP50-95	0,7064	70,64 %	Métrica más exigente, con umbrales IoU entre 0,50 y 0,95.




Figura 17. Resumen de métricas del modelo YOLOv8.

Los resultados muestran un desempeño alto en Precision, Recall y mAP50. La métrica mAP50-95 es menor, lo cual es esperable porque exige mayor precisión en la superposición entre las cajas reales y predichas. Esto indica que el modelo detecta correctamente la mayoría de los campos, aunque la localización exacta de algunos objetos puede mejorarse.

Interpretación de métricas

Métrica	Qué mide	Lectura para el proyecto
Precision	Confiabilidad de las detecciones realizadas.	Si el modelo marca un campo, generalmente lo marca correctamente.
Recall	Capacidad para encontrar objetos reales.	El modelo omite pocos campos relevantes del ticket.
mAP50	Calidad general de detección con IoU 0,50.	Mide si la caja predicha se superpone razonablemente con la caja real.
mAP50-95	Precisión media con varios niveles de exigencia.	Evalúa con mayor rigor la calidad de localización de las cajas.

Predicción limpia - test / Factura_O_Documento_Equivalente_288389222_752902943_0_1_png.rf.825af94a4646bda2b5b699c0a1...



HOSPITAL SAN JUAN BAUTISTA E.S.E.
NIT 890701459 - 4 COD: 731680090501
CALLE 11 CARRERAS 9 Y 10
CHAPARRAL
CUFE:
55aa431927116e370b4cd7cd9b46229157b9d307bdfbc33548aca15a4115121628c35
37135fa544ccaecfe597225

FECHA: 24/02/2025 06:59
VENO: 27/03/2025
PAGINA: 1

Predicciones

1. factura (0.97)
2. paciente (0.53)
3. ingreso (0.83)
4. autorización (0.88)
5. valor_unitario (0.33)
6. cantidad (0.87)
7. código (0.74)
8. valor_unitario (0.65)
9. cantidad (0.84)
10. cantidad (0.81)
11. total (0.73)
12. copago (0.75)
13. cuota_moderadora (0.28)
14. cuota_moderadora (0.81)
15. cuota_moderadora (0.44)

FACTURA ELECTRÓNICA DE VENTA ORIGINAL


NUMERO ID: 2 9033841 NOMBRE: BLANCA MARIA GARAY TIBAGUE TELEFONO: 2460095-2460077 DIRECCION: CALLE 11 CARRERAS 9 Y 10 MUNICIPIO: CHAPARRAL EDAD: 80 No. HISTORIA: 65627903 FECHA INGRESO: 24-02-2025 AUTORIZACION: 65650233032	NIT: 900156264 - 2 EMPRESA: NUEVA EPS S.A.-NUEVA EPS SUBSIDIADO 2018 DIRECCION EMPRESA: CL 31 4B-40 BARRIO CADIZ IBAG CONTRATO: EPSS41 - NUEVA EPS SUBSIDIADO 2018 S.O.A.T # TIPO USUARIO TIPO AFILIADO P.P. 248 P.S. 11 FECHA SALIDA: 24-02-2025	CODIGO DESCRIPCION VLR. UNITARIO CNT. TOTAL 903841 GLUCOSA EN SUERO LCR U OTRO FLUIDO DIFER. A ORINA 5 19.000.00 95.000.00 903426 HEMOGLOBINA GLICOSILADA AUTOMATIZADA 8 69.400.00 555.200.00 TOTAL FACTURA: 650.200.00 VALOR A PAGAR POR ENTIDAD o EPS: 650.200.00 VALOR A PAGAR POR EL USUARIO: 0.00 ABONOS: 0.00 CUOTA MODERADORA: 0.00 SALDO POR PAGAR POR EL USUARIO: 0.00 VALOR PAGADO POR EL USUARIO: 0.00 VALOR NO PAGADO POR EL USUARIO: 0.00
--	---	--

SON EN TOTAL:
 Valor a pagar por la empresa:
 OCHENTA Y OCHO MIL CUATROCIENTOS PESOS COLOMBIANOS CON CERO CENTAVOS
Observación:
 NOTA: - - AUTORIZACION: 65650233032 PACIENTE: CC-65627903-BLANCA MARIA GARAY TIBAGUE; INGRESO: 316 - ABONO PACIENTE: 0.00 EN PESOS
 Firma Paciente y/o Representante: _____ Responsable Facturación PAULA ANDREA RAMOS
 C.C No: _____ Sede: EMPRESA 01 SEDE 001 SEDE HOSP. SAN JUAN BAUTISTA
 Fecha Rec: _____

*** Items Particionados por Control de Topes por Usuario**
 Esta factura se asima a una LETRA DE CAMBIO, Art 774 Código del Comercio y una vez vencido el plazo para cancelarla a que se refiere el Dec. 723/97, se causaran intereses moratorios en la cuantía fijada por la Superintendencia Bancaria. Exentos de Impuesto según Artículo 476 del Estatuto Tributario
 Factura Impresa por Computador SOMOS GRANDES CONTRIBUYENTES
 RESOLUCION NO. 18764069094052 DEL 16/04/2024 DESDE EL NO. FE 3127513 HASTA EL NO. FE 10000000
 Factura SAS Nit: 900399741-7, Proveedor tecnológico. Software: PL-Colab

Figura 19. Predicción limpia del modelo sobre imagen de test.


Anotación real



Anotaciones reales

1. factura
2. paciente
3. ingreso
4. autorización
5. valor_unitario
6. cantidad
7. código
8. valor_unitario
9. cantidad
10. cantidad
11. total
12. copago
13. cuota_moderadora

Predicción del modelo



Predicciones

1. factura (0.97)
2. paciente (0.53)
3. ingreso (0.83)
4. autorización (0.88)
5. valor_unitario (0.33)
6. cantidad (0.87)
7. código (0.74)
8. valor_unitario (0.65)
9. cantidad (0.84)
10. cantidad (0.81)
11. total (0.73)
12. copago (0.75)
13. cuota_moderadora (0.28)
14. cuota_moderadora (0.81)
15. cuota_moderadora (0.44)

Figura 20. Comparación visual entre anotación real y predicción del modelo.

La comparación visual permite detectar aciertos, omisiones y diferencias de localización. En el ejemplo analizado, el modelo generó 15 detecciones frente a 13 anotaciones reales, lo que permite revisar posibles falsos positivos o variaciones en la interpretación de campos cercanos.

PIPELINE FINAL DEL SISTEMA

El producto final puede describirse como un pipeline automatizado para procesar tickets hospitalarios. El flujo integra validación de datos, preparación, entrenamiento y evaluación.

Etapa	Descripción
1. Ingreso del dataset	Se cargan imágenes de tickets organizadas en train, valid y test.
2. Validación de anotaciones	Se revisan clases esperadas, bounding boxes inválidas y estructura de archivos CSV.
3. Análisis exploratorio	Se generan tablas y gráficos sobre imágenes, clases, anotaciones, resolución y ubicación espacial.
4. Procesamiento visual	Se aplican escala de grises, Gaussian Blur, binarización y Canny para analizar estructura documental.
5. Conversión a YOLO	Se convierten coordenadas de bounding boxes y se genera data.yaml.
6. Entrenamiento	Se entrena YOLOv8n con las imágenes y labels generados.
7. Evaluación	Se calculan Precision, Recall, mAP50 y mAP50-95 sobre test.
8. Predicción visual	Se generan imágenes con cajas, numeración y referencias para interpretar los resultados.
9. Futuro OCR	Las regiones detectadas podrían enviarse a OCR para extraer texto automáticamente.

16. PRODUCTO FINAL:

El producto final consiste en una solución prototipo basada en visión por computadora para la detección de campos administrativos en tickets hospitalarios. Se desarrolla desde el espacio curricular Procesamiento de Imágenes e integra técnicas clásicas de procesamiento visual con aprendizaje profundo.

- Notebook ejecutable con el flujo completo del proyecto.
- Dataset convertido a formato YOLO.
- Modelo YOLOv8 entrenado para detectar campos del ticket.
- Evidencias de procesamiento de imágenes: escala de grises, binarización, Gaussian Blur y Canny.
- Predicciones visuales limpias con numeración y referencias laterales.
- Evaluación del modelo mediante métricas de detección.
- Documentación técnica y diseño ABP para presentación y defensa.

Vinculación con la comunidad: el proyecto puede servir como base para una futura herramienta de apoyo a instituciones de salud que necesiten digitalizar tickets o comprobantes de manera más eficiente, reduciendo carga manual y errores administrativos.

Link al Repositorio:

<https://github.com/IanMarini/ISPC-Procesamiento-Imagenes-Proyecto-Grupo2>

17. EVALUACIÓN TÉCNICA ESPERADA:

El modelo se evalúa mediante métricas propias de detección de objetos. Estas métricas permiten analizar si el sistema detecta correctamente los campos y si las cajas predichas se ubican en zonas similares a las anotaciones reales.

Métrica	Qué mide	Interpretación esperada
Precision	Proporción de detecciones correctas entre todas las detecciones realizadas.	Alta precisión indica que el modelo genera pocos falsos positivos.
Recall	Proporción de objetos reales que el modelo logra encontrar.	Alto recall indica que el modelo omite pocos campos relevantes.
mAP50	Precisión media con un umbral IoU de 0.50.	Permite evaluar la calidad general de detección.
mAP50-95	Precisión media con umbrales IoU entre 0.50 y 0.95.	Es más exigente y evalúa mejor la calidad de localización.

18. LIMITACIONES Y MEJORAS FUTURAS:

Limitaciones:

- El modelo puede presentar dificultades con tickets de baja calidad de impresión.
- Las imágenes borrosas, recortadas o con iluminación irregular pueden reducir la precisión.
- La superposición entre campos o textos cercanos puede afectar la localización de cajas.
- El dataset utilizado es acotado para un escenario productivo real.
- El sistema detecta regiones, pero no extrae automáticamente el texto contenido en ellas.

Mejoras futuras:

- Entrenar con mayor cantidad y variedad de ejemplos.
- Aplicar aumento de datos para robustecer el modelo ante rotaciones, ruido y cambios de iluminación.
- Incorporar OCR sobre las regiones detectadas.
- Integrar reglas de validación automática para los campos extraídos.
- Desarrollar una interfaz simple para cargar tickets y visualizar detecciones.
- Conectar el prototipo con sistemas administrativos hospitalarios.

CONCLUSIÓN GENERAL DEL PROYECTO

El proyecto CoberturaMed logró construir un prototipo funcional para la detección automática de campos administrativos en tickets hospitalarios mediante procesamiento de imágenes y YOLOv8.

El análisis exploratorio permitió comprobar que el dataset posee una estructura adecuada: las imágenes están distribuidas en train, valid y test, las clases se encuentran relativamente equilibradas y los campos presentan patrones espaciales coherentes dentro del documento.

Las técnicas clásicas de procesamiento de imágenes permitieron analizar la estructura visual de los tickets, mientras que la conversión al formato YOLO posibilitó el entrenamiento de un modelo de detección de objetos.

Los resultados obtenidos muestran un desempeño sólido para un prototipo académico: Precisión de 95,85 %, Recall de 93,39 %, mAP50 de 96,85 % y mAP50-95 de 70,64 %. Esto indica que el modelo detecta correctamente la mayoría de los campos, aunque todavía existe margen de mejora en la localización precisa de objetos pequeños o cercanos.

Desde la perspectiva aplicada, CoberturaMed constituye una base técnica para futuras soluciones de automatización documental en instituciones de salud. La integración con OCR, validación de campos e interfaces de usuario permitiría avanzar hacia una herramienta más completa y cercana a un escenario productivo.



19. BIBLIOGRAFÍA:

- Canny, J. (1986). A computational approach to edge detection. IEEE Transactions on Pattern Analysis and Machine Intelligence, PAMI-8(6), 679-698. <https://ieeexplore.ieee.org/document/4767851>
- OpenCV. (s. f.). Canny Edge Detection. OpenCV documentation. Recuperado el 9 de junio de 2026, de https://docs.opencv.org/4.x/da/d22/tutorial_py_canny.html
- OpenCV. (s. f.). Image Thresholding. OpenCV documentation. Recuperado el 9 de junio de 2026, de https://docs.opencv.org/3.4/d7/d4d/tutorial_py_thresholding.html
- OpenCV. (s. f.). Smoothing Images. OpenCV documentation. Recuperado el 9 de junio de 2026, de https://docs.opencv.org/4.x/d4/d13/tutorial_py_filtering.html
- Otsu, N. (1979). A threshold selection method from gray-level histograms. IEEE Transactions on Systems, Man, and Cybernetics, 9(1), 62-66. <https://doi.org/10.1109/TSMC.1979.4310076>
- Ultralytics. (s. f.). YOLOv8. Ultralytics documentation. Recuperado el 9 de junio de 2026, de <https://docs.ultralytics.com/models/yolov8/>